IDEA AUDITION 実測計画
「作る意味があったのか」を数字で示す

チーム VICTORY ／ 2026-11-09 作成 ／ 提出締切 2026-11-10（火）19:00 に間に合わせる版

> **ねらい**：ピッチの PROOF のスライドに載せる数字を、明日までに実測でそろえる。
> 「正しく作ったので 0件でした」ではなく、**CAMP や合意の反映を外すと実際に何が起きるか**を同じ条件で比べ、その差を見せる。あわせて、実際に人が使ったときの効果（時間・手戻り・納得感）を、ふつうのチャット AI と比べて測る。

1 何を測るか（全体像）

記号	実験	示したいこと	方法	人
M1	同時のブザー：二重合格	CAMP なしでは合格が二重に確定する。ありでは 0	シミュレーター	0人
M2	合意の変更：古い前提の案	合意が変わった後に、古い前提の案が舞台に出てしまう割合。CAMP ありでは 0%	シミュレーター	0人
M3	一度否定した方向の再提示	合意を反映しないと、否定した方向の案がまた出る。反映するとどれだけ減るか	自動の会議＋Gemini	0人（確認1人）
M4	合意から次の案までの秒数	人が決めてから、何秒で次の案に反映されるか	M3・M6のログ	0人
M5	待ち時間の削減	開始→最初のキャラ、優勝→企画書の待ち時間	測定済み＋再測定	0人
M6	15分でいくつ見て、何分で決まったか	ふつうのチャット AI で決める会議と比べた効果（案の数・時間・納得感・理由を言えるか）	ユーザー実験	12〜16人＋評価者2〜3人

必要な人数（合計）

12〜16人	2〜3人	2人	1人
M6 の参加者	最終案の評価者	進行役・記録係	M3 の判定の抜き取り確認
（3〜4人 × 4グループ）	（参加しない人）	（チームから、各回）	（チームから）

M1・M2・M3・M4・M5 は人を集めずに回せる。人が要るのは M6 と評価だけ。4グループは「順番」と「テーマ」の組み合わせをそろえるための最小数（2 × 2）。集まれば 6グループにする。

2 M1：同時のブザーで、合格は1回だけか

シミュレーター　人：0人　準備 約3時間・実行 数分

やり方

本物のサーバーのアクター（`SessionActor`）に、偽の審査員を4〜8人つなぎ、時計と通信の遅れを操作できる環境で何度も審査させる。同じ入力を「守りあり（今の CAMP）」と「守りなし（素朴な作り）」の両方に流して比べる。

守りなし（素朴な作り）の中身	守りあり（CAMP）
各ブラウザが「全員押した」と判断したら、それぞれが合格を送る	全員一致はサーバーが1か所で判定し、1回だけ確定
同じ操作の再送（返事が来ず送り直した）も、そのたびに実行	commandId で重複を捨てる
票がどの挑戦者あてか確かめない（交代の直前に押した票が、次の人に入る）	挑戦者の ID を見て、前の挑戦者への票は断る

条件（各 1,000回）

- 4人がほぼ同時に押す（0〜10ms の差）／ 最後の1人が連打 ／ 交代の直前に押す
- 通信の遅れ：0・50・200ms（ばらつきあり）、返事の取りこぼしで再送：0%・10%
- 参加人数：2・4・8人

測る数字

- **二重合格の回数**（サーバーが出した「合格」イベントの数で数える。画面の光り方では数えない）
- **別の挑戦者に入った票の数**、最後に全員の画面の状態が一致した割合

ピッチの言い方（例）：「4人が同時に押す条件で1,000回。素朴な作りでは二重合格が N回。CAMP では 0回」

3 M2：合意が変わったあと、古い前提の案が出ないか

シミュレーター　人：0人　準備 約3時間・実行 数分

やり方

AI の返事の遅さと到着の順番を自由に変えられる「偽の AI」を使う。案を頼んでいる最中に合意を変え（例：広告 → 口コミ）、届いた案のうち**古い合意をもとに作った案が舞台に出たか**を数える。

比べる3つ	中身
なし	届いた案をそのまま出す
今の作り	合意が変わった瞬間にストックの古い案は捨てる。ただし、**変わる前に頼んで、変わった後に届いた案**はそのまま入る
あり（直したあと）	案が届いた時点で「どの版の合意をもとに作ったか」を今の合意と照らし、古ければ使わない

> **先に直すこと**：コードを確認したところ、「今の作り」には上の穴がある（`ensureStock` が届いた案の合意の版を見ていない。案が無いときは古い案を1件残す作りもある）。M2 の「あり」は、この穴を直した版で測る。直す前の数字も「今の作り」として残し、改善の幅として出す。

条件（代表 1,000回、ほかは各 100回）

- AI の返事の遅さ：0.5・2・5秒 ／ 到着の順番：頼んだ順・逆順・ばらばら
- 生成中の合意の変更：1回・3回 ／ 同時に頼む案の数：1・3

測る数字

- **古い前提の案が舞台に出た割合**（なし ／ 今の作り ／ あり）
- 合意が変わってから、新しい合意の案が舞台に出るまでの秒数
- 合意の変更で無駄になった生成の数（捨てた案の数）

4 M3：一度否定した方向が、また出てこないか

自動の会議＋本物の Gemini　人：0人（確認に1人）　準備 約2時間・実行 約2時間

やり方

人を集めずに測るため、**決まった台本の会議**を自動で流す。台本では、はじめに出た方向を審査員がはっきり否定し、別の方向で合意する（例：「広告で一気に広める」→「広告はなし。学生の口コミで広げよう」）。そのあと出てくる次の案 10件に、否定した方向が入っているかを数える。

条件	中身
A：合意を反映しない	会議の内容を、次の案づくりに渡さない
B：合意を反映する（今の作り）	合意メモを次の案づくりに渡し、古い前提の案は捨てる

- 台本：テーマ3つ × 否定する方向2つ ＝ 6本。各条件で 各3回まわす（合計 36回、案は約 360件）
- 判定：各案が「否定した方向」を含むかを Gemini に判定させる。チームの1人が 20%を抜き取りで見て、判定のずれを数える
- モデル・プロンプト・案の数は、A と B でそろえる

測る数字

- **否定した方向の再提示率**（A と B）
- 合意の反映率：合意した条件（「口コミで」など）を満たす案の割合

ピッチの言い方（例）：「否定した方向が、反映しないと次の10案のうち X 件また出た。IDEA AUDITION では Y 件」

5 M4：合意から次の案までの秒数

M3 と M6 のログから取る。追加の実験はいらない。

- 起点：合意メモが更新された時刻（`CONSENSUS_UPDATED`）
- 終点：その合意の版をもとに作った案が、はじめて舞台に出た時刻（`CANDIDATE_SPAWNED` の `basedOnConsensus`）
- 出す数字：中央値と 95%点（p50・p95）。本物の Gemini で、本番の環境（Cloud Run）で測る

6 M5：待ち時間の削減（測定済み＋再測定）

場面	前	今	しくみ
開始 → 最初のキャラが出るまで	約1.5〜3.0秒	**約0.06秒**	ロビーでテーマを入れている間に、最初の案を作っておく
優勝 → 企画書が出るまで	11〜13秒	**0秒**	決勝の間に、全員分の企画書を作り置きする

本番で各 10回測り直して、中央値と最大を出す（今は 2〜4回の測定）。テーマを入れてすぐ始めた場合の数字（作り置きが間に合わない場合）も、隠さず一緒に出す。

7 M6：15分でいくつ見て、何分で決まったか（ユーザー実験）

ユーザー実験 参加 12〜16人 評価 2〜3人 1グループ 約45分

比べる2つ

X：ふつうのチャット AI
1台の画面で Gemini（チャット）に案を出させ、みんなで話して1案に決める。

Y：IDEA AUDITION
全員がそれぞれの PC で参加し、ブザーで選んで決勝で磨き、優勝を決める。

他社の製品を前面に出さないルールに合わせ、比べる相手も Google の Gemini にする。どちらも同じモデルの世代を使う。

進め方（1グループ 3〜4人、約45分）

1. 説明 5分：目的は伝えず「アイデアを1つに決めてもらう」とだけ伝える
2. 1回目 15分（X か Y）→ アンケート 3分
3. 2回目 15分（もう一方、別のテーマ）→ アンケート 3分
4. ふり返り 3分：どちらの決め方がよかったか、なぜか

同じ人が両方やる（人の差を消すため）。どちらを先にやるかと、どのテーマをどちらで使うかを、グループごとに入れ替える。

グループ	1回目	2回目
1	X ＋ テーマ甲	Y ＋ テーマ乙
2	Y ＋ テーマ甲	X ＋ テーマ乙
3	X ＋ テーマ乙	Y ＋ テーマ甲
4	Y ＋ テーマ乙	X ＋ テーマ甲

テーマ甲・乙は難しさが近いものにする（例：「大学の学食をもっと楽しくする企画」「図書館をもっと使いたくなる企画」）。

測る数字

数字	取り方
15分で見た案の数	X：AI の返答に出た案を記録係が数える ／ Y：舞台に出たキャラの数（ログ）
1案に決まるまでの時間	X：記録係がストップウォッチ ／ Y：開始から優勝までの時刻（ログ）
話した回数・偏り	Y：発言のログ ／ X：記録係が「誰が話したか」を正の字で数える
選んだ理由を言えるか（Own the Why）	アンケートで「なぜこの案にしたか」を各自が自由に書く。理由の数と具体さを、評価者が数える
納得感・自分たちで選んだ感・楽しさ	アンケート（5段階）
最終案の質	評価者が、条件を伏せて「新しさ・実現できるか・テーマに合うか」を各5点で採点

評価者の採点

最終案（各グループ2案、合計8〜12案）を同じ書式（タイトル＋3行の説明）にそろえ、どちらの条件で出た案かを伏せて、並び順もばらばらにして渡す。評価者はグループに参加していない人にする。

> **当日の環境の注意**：大学の Wi-Fi では、ブラウザどうしの音声通話がつながらないことがある（今の作りは TURN サーバーが無い）。M6 は同じ部屋で**顔を合わせて話し**、アプリの通話はオフにする。声の文字起こしは使う場合、全員ヘッドセットにして、ほかの人の声を拾わないようにする。ネットが不安ならテザリングを用意する。

8 段取り（11/9 夜 〜 11/10 19:00）

時間	やること	担当の目安
11/9 夜	参加者と評価者を集める（グループの時間を決める）。アンケートを Google フォームで作る。テーマ甲・乙と M3 の台本を決める	人集め：チーム全員
11/9 夜	M2 の穴を直す。M1・M2 のシミュレーターを作って回す。ログを書き出すスクリプトを作る	開発（Claude Code と1人）
11/10 午前	M3 の自動の会議を流す（本番の Gemini）。M5 を本番で測り直す	開発
11/10 10:00〜15:00	M6 のユーザー実験。2つの部屋で並行すれば 4グループが 約1.5時間、1部屋なら 約3時間	進行役・記録係を2人ずつ
11/10 15:00〜16:30	評価者の採点。M3 の判定の抜き取り確認。ログとアンケートを集計してグラフにする	評価者・開発
11/10 16:30〜18:30	PROOF のスライドと README・説明ドキュメントに反映	発表担当
11/10 19:00	提出	

当日までに用意するもの

- M6 用の PC：Y は1人1台（3〜4台 × 部屋の数）、X は1台＋大きめの画面。ヘッドセット人数分
- 本番の URL で部屋を作れることの確認（同じ回線から1時間に作れる部屋は10個まで）
- 記録用紙（X の案の数・時間・発言の正の字）、ストップウォッチ
- 同意の説明：ログとアンケートを、名前を伏せて発表に使うこと

9 ピッチにどう出すか

CAMP の説明は「問題（10枚目の絵）」→「本当に効くのか（実測）」の2枚にする。実測のスライドは次の3つに絞る。

見せ方	使う数字
CAMP がないと、こう壊れる → あると 0	M1 の二重合格、M2 の古い前提の案（なし ／ 今の作り ／ あり）
会議の手戻りが減る	M3 の再提示率、M4 の合意から次の案までの秒数
人が使うと、こう変わる	M6 の「見た案の数・決まるまでの時間・理由を言えた数・納得感」、M5 の待ち時間

10 正直に出すためのルール

- どの数字にも「シミュレーター／自動の会議／ユーザー実験」「何回・何人」を必ず添える
- 「1,000回で 0件」は、その条件で起きなかったという意味で、どんな環境でも起きないという証明ではない
- M6 は 12〜16人の小さな実験。統計的に勝ったとは言わず、「この人数ではこうだった」と言う
- よくならなかった数字も、ドキュメントには載せる。ピッチに載せるかは、そのうえで選ぶ
- 実験の生ログ（JSONL）、集計スクリプト、アンケートの元データは、リポジトリの `docs/experiments/` に残し、1つのコマンドで集計し直せるようにする

11 作るもの（開発のタスク）

タスク	中身	目安
M2 の穴を直す	案が届いた時点で合意の版を照らし、古ければ使わない。テストを足す	1時間
シミュレーター（M1・M2）	偽の審査員・偽の AI・時計を操作する。守りあり／なしを切り替える。結果を JSONL に出す	3〜4時間
自動の会議（M3）	台本どおりに発言を送る審査員ボット。条件 A／B の切り替え。案の判定を Gemini で	2時間
ログの書き出し（M4・M6）	部屋ごとのイベント・発言・判定を Firestore から書き出す	1時間
集計とグラフ	全実験の数字を表とグラフにする	1〜2時間